

DDPM与Flow Matching图像生成实验报告

宁尚哲 PB24000099

March 28, 2026

Abstract

本报告详细阐述了去噪扩散概率模型（DDPM）和Flow Matching的图像生成实现。我们从基础的DDPM框架出发，实现了前向加噪、逆向去噪、模型训练和RePaint图像补全等核心功能。在此基础上，我们进一步实现了条件生成（文生图）、大规模数据集扩展（177张图片）、VAE潜空间扩散模型以及Flow Matching连续流模型。实验结果表明，通过合理的参数优化和架构改进，模型能够生成高质量的图像，并在多类别生成任务中表现出良好的条件控制能力。

关键词： DDPM, Flow Matching, VAE, 图像生成, 条件生成, RePaint

1 引言

去噪扩散概率模型（Denoising Diffusion Probabilistic Models, DDPM）[1]是近年来图像生成领域的重要突破。DDPM通过逐步添加噪声将图像转化为纯高斯噪声，然后学习逆向过程从噪声中恢复图像。这种方法在图像质量、采样多样性和训练稳定性方面都表现出色。

Flow Matching[2]是另一种生成建模方法，它通过学习连续时间下的向量场来实现从噪声到数据的转换。与DDPM相比，Flow Matching具有更快的采样速度和更稳定的训练过程。

本实验的目标是实现并比较这两种方法，探索它们在图像生成任务上的性能。我们首先实现基础的DDPM框架，然后扩展到条件生成、大规模数据集和潜空间扩散，最后实现Flow Matching方法。

2 相关工作

2.1 去噪扩散概率模型

DDPM的核心思想是通过前向扩散过程 $q(x_t|x_{t-1})$ 逐步添加噪声，最终将图像 x_0 转化为纯高斯噪声 x_T 。逆向过程 $p_\theta(x_{t-1}|x_t)$ 则学习如何从噪声中恢复图像。

前向扩散过程定义为：

$$q(x_t|x_{t-1}) = \mathcal{N}(x_t; \sqrt{1 - \beta_t}x_{t-1}, \beta_t I) \quad (1)$$

其中 β_t 是噪声调度参数， I 是单位矩阵。

逆向过程通过神经网络学习：

$$p_\theta(x_{t-1}|x_t) = \mathcal{N}(x_{t-1}; \mu_\theta(x_t, t), \Sigma_\theta(x_t, t)) \quad (2)$$

2.2 Flow Matching

Flow Matching学习连续时间下的向量场 $v_t(x)$ ，使得从噪声分布到数据分布的转换路径最优。最优传输（Optimal Transport, OT）路径是Flow Matching的一种特殊情况，它直接计算从噪声到数据的最优路径。

OT路径定义为:

$$\psi_t(x) = (1 - (1 - \sigma_{\min})t)x_0 + tx_1 \quad (3)$$

目标向量场为:

$$u_t(x) = \frac{x_1 - (1 - \sigma_{\min})x_0}{1 - (1 - \sigma_{\min})t} \quad (4)$$

2.3 变分自编码器

变分自编码器 (VAE) [3]通过编码器将图像压缩到潜空间, 然后通过解码器重建图像。VAE的潜空间具有连续性和平滑性, 适合作为扩散模型的输入。

VAE的损失函数包括重建损失和KL散度损失:

$$\mathcal{L}_{VAE} = \mathbb{E}_{x \sim p_{data}} [\|x - \hat{x}\|^2] - \beta D_{KL}(q(z|x) \|\mathcal{N}(0, I)) \quad (5)$$

3 实现架构

3.1 基础DDPM实现

3.1.1 前向加噪过程

我们实现了基于闭式解的前向加噪过程。给定原始图像 x_0 和时间步 t , 加噪后的图像 x_t 可以通过闭式解直接计算:

$$q(x_t|x_0) = \mathcal{N}(x_t; \sqrt{\bar{\alpha}_t}x_0, (1 - \bar{\alpha}_t)I) \quad (6)$$

其中 $\bar{\alpha}_t = \prod_{s=1}^t (1 - \beta_s)$ 是累积信号保留比例。




Figure 1: 基础DDPM模型训练流程

3.1.2 逆向去噪过程

逆向去噪过程通过神经网络预测噪声，然后计算后验分布的均值和方差：

$$\mu_{\theta}(x_t, t) = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_{\theta}(x_t, t) \right) \quad (7)$$

$$\sigma_t^2 = \frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t} \beta_t \quad (8)$$




Figure 2: 基础sampling采样

3.1.3 网络架构

我们采用UNet架构作为噪声预测网络。UNet包含编码器-解码器结构，通过跳跃连接保留多尺度信息。网络还包含正弦位置嵌入来编码时间步信息。

3.2 条件生成（文生图）

为了实现条件生成，我们在网络中引入类别嵌入。对于两类别数据集，我们使用简单的0/1标量编码，并通过嵌入层将其映射到与时间嵌入相同的维度。

条件生成的损失函数为：

$$\mathcal{L}_{cond} = \mathbb{E}_{x_0, c, t} [\|\epsilon - \epsilon_{\theta}(x_t, t, c)\|^2] \quad (9)$$

其中 c 是类别标签， $\epsilon_{\theta}(x_t, t, c)$ 是条件噪声预测。

3.3 VAE潜空间扩散

为了处理大规模数据集，我们引入VAE将图像压缩到潜空间。VAE编码器输出4通道的 4×4 特征图，DDPM直接在这个潜空间进行扩散。

潜空间缩放是关键。我们计算所有训练数据潜空间的标准差 σ_z ，然后使用缩放因子 $s = 1/\sigma_z$ 对潜空间进行归一化。




Figure 3: 文本向量嵌入




Figure 4: VAE我参考的实现框架[6]

3.4 Flow Matching实现

Flow Matching学习连续时间下的向量场。我们采用最优传输路径，通过OT路径计算目标向量场，然后训练网络预测这个向量场。

CFM损失函数为：

$$\mathcal{L}_{CFM} = \mathbb{E}_{x_0, x_1, t} [\|v_\theta(\psi_t(x_0, x_1, t), t, c) - u_t(x_0, x_1, t)\|^2] \quad (10)$$

其中 u_t 是目标向量场， v_θ 是网络预测的向量场。

3.5 RePaint图像补全

RePaint[4]是一种基于DDPM的图像补全方法。它通过跳跃采样（Gibbs sampling）对mask区域进行多次采样，同时保持非mask区域不变。




Figure 5: flow matching架构




Figure 6: repaint论文思路

4 实验

4.1 实验设置

我们使用datasets-3数据集，包含177张图片，分为两个类别（猫和狗）。该数据集来源于Kaggle的Animal Faces数据集[5]。图像大小调整为 64×64 像素。训练参数如表1所示。

本实验在以下硬件环境下进行：

Table 1: 训练参数设置

参数	值
图像大小	64×64
批次大小	8-16
扩散时间步数	300
学习率	$1e-4$
训练轮数	5000
优化器	Adam

- 处理器: Intel Core i9
- 显卡: NVIDIA GeForce RTX 4070
- 训练时长: 30分钟至1小时 (不同模型时长不一样)

4.2 基础DDPM实验

4.2.1 训练过程

我们首先实现了基础的DDPM训练。训练过程中，损失函数稳定下降，最终收敛到较低水平。图1展示了训练损失曲线。

4.2.2 图像生成结果

图2展示了基础DDPM生成的图像。在Loss收敛到0.02以下，模型生成图像依然存在很多噪声，细节和纹理仍有改进空间。



(a) DDPM生成图像

Figure 7: 基础DDPM生成结果

4.2.3 不同loss对比

我发现，单图训练时loss降低到0.4还是比较高的值，loss从0.4到0.2画质清晰度会有一个突变：




Figure 8: 不同loss下的质量对比

4.3 条件生成实验

4.3.1 类别控制效果

通过引入类别嵌入，模型能够根据类别标签生成对应类别的图像。图3展示了不同类别的生成结果对比。

从图3可以看出，模型成功学习了不同类别的特征。类别0生成的图像具有猫的特征（尖耳朵、胡须），而类别1生成的图像具有狗的特征（更长的嘴部、不同的耳朵形状）。

4.4 VAE潜空间扩散实验

4.4.1 潜空间缩放效果

潜空间缩放是VAE+DDPM成功的关键。表2对比了有无缩放的效果。

Table 2: 潜空间缩放效果对比

方法	最终损失	生成质量
无缩放	~ 10	纯噪声
有缩放	0.8	结构清晰

4.4.2 VAE训练效果与潜空间可视化

VAE的训练效果直接决定了后续DDPM潜空间训练的效果，VAE的loss要尽可能训练多次降低到一个相对较低的水平，且尤其需要结合重建图像决定是否可以进行下一步的潜空间训练，




Figure 9: 条件生成结果对比

不能仅仅通过loss判断。还需要结合潜空间UMAP可视化图，确保两类点没有聚集在一起形成一个点，以及模型对两类不同特征的区分度。

下图展示了VAE的训练效果和潜空间的UMAP可视化。




Figure 10: VAE训练效果与潜空间可视化

4.4.3 VAE+DDPM生成结果

然后就是经过了很多很多次的反复炼丹工作以及调参模型调优、优化网络等工作，数据集33张扩展到177张图片时候模型终于学到了比较不错的特征。下图展示了VAE+DDPM的生成结果。与像素空间DDPM相比，VAE+DDPM在潜空间进行扩散，训练效率更高，生成质量更好。可以发现猫和狗的特征都能学习不错，每次“开盒”出不同的图片。



Figure 11: VAE+DDPM生成结果

4.4.4 无分类器引导 (CFG)

我们实现了无分类器引导 (Classifier-Free Guidance, CFG) 来增强条件控制。下图展示了不同CFG强度的效果。



Figure 12: 无分类器引导效果对比

4.5 Flow Matching实验


4.5.1 训练优化

Flow Matching的训练面临loss发散的问题。我们进行了以下优化：


1. **学习率调度优化**：将ReduceLROnPlateau的patience从50增加到100，factor从0.5增加到0.7，避免学习率过早触底。
2. **梯度裁剪优化**：将梯度裁剪阈值从0.5增加到1.0，允许更大的梯度更新。
3. **EMA衰减系数优化**：将EMA衰减系数从0.9999降低到0.999，减少过拟合。
4. **OT路径数值稳定性**：将防除零常数从 $1e-6$ 增加到 $1e-4$ ，数值裁剪范围从 $[-10,10]$ 调整到 $[-5,5]$ ，减少loss波动。
5. **时间编码优化**：将时间编码缩放因子从1000降低到100，避免数值范围过大导致梯度爆炸。

4.5.2 Flow Matching生成结果

下图展示了Flow Matching的生成结果。与DDPM相比，Flow Matching的采样过程更平滑，生成速度更快。



(a) Flow Matching类别0



(b) Flow Matching类别1

Figure 13: Flow Matching生成结果

4.6 RePaint图像补全实验

4.6.1 补全效果

图8展示了RePaint图像补全的结果。模型能够有效地补全mask区域，同时保持非mask区域不变。

5 结果与分析

5.1 方法对比

表3对比了不同方法的性能。



Figure 14: RePaint图像补全结果

Table 3: 不同方法性能对比

方法	训练稳定性	生成质量	采样速度	条件控制
基础DDPM	中	中	慢	无
条件DDPM	中	中	慢	有
VAE+DDPM	高	高	中	有
Flow Matching	高	高	快	有

5.2 横向对比分析

5.2.1 生成质量对比

下图展示了不同方法在同一类别上的生成结果对比。



Figure 15: 类别0生成质量横向对比

可以看出：

- **基础DDPM**: 生成的图像结构基本清晰，但细节较为模糊。
- **VAE+DDPM**: 生成的图像细节更丰富，纹理更清晰，潜空间扩散的优势明显。
- **Flow Matching**: 生成的图像质量最高，边缘锐利，颜色鲜艳，连续流模型的优势显著。



Figure 16: 类别1生成质量横向对比

5.3 优化策略效果

5.3.1 Flow Matching优化效果

表4展示了Flow Matching优化前后的效果对比。

Table 4: Flow Matching优化效果

优化项	优化前	优化后
学习率调度	Loss震荡	Loss稳定下降
梯度裁剪	梯度爆炸	梯度正常
OT路径数值	Loss波动大	Loss波动小
EMA衰减	过拟合明显	泛化能力提升

5.3.2 VAE优化效果

VAE训练中的关键优化包括：

1. **KL退火**：前期专注于重建，后期逐渐引入KL散度约束。
2. **GroupNorm替代BatchNorm**：避免小batch size导致的统计不稳定。
3. **潜空间缩放**：计算标准差并进行归一化，确保潜空间方差接近1。

6 讨论

6.1 方法优势

1. **Flow Matching**：连续时间模型，采样速度快，训练稳定。
2. **VAE+DDPM**：潜空间扩散降低计算复杂度，适合大规模数据集。
3. **条件生成**：通过类别嵌入实现精确的条件控制。

6.2 方法局限

1. **DDPM采样速度**: 需要逐步去噪, 采样速度较慢。
2. **VAE重建损失**: VAE的重建损失可能影响生成质量。
3. **Flow数值稳定性**: OT路径在 $t \rightarrow 1$ 时可能出现数值爆炸, 需要仔细处理。

6.3 未来工作

1. **更复杂的条件**: 引入CLIP文本编码, 实现真正的文生图。
2. **更大规模数据集**: 扩展到更多类别和更多图片。
3. **更高效的采样**: 探索DDIM、DPM-Solver等快速采样方法。
4. **更好的架构**: 引入Transformer架构, 提升模型容量。

7 结论

本实验成功实现了DDPM和Flow Matching的图像生成系统。我们从基础的DDPM框架出发, 逐步扩展到条件生成、大规模数据集、VAE潜空间扩散和Flow Matching。实验结果表明:

1. 基础DDPM能够生成结构清晰的图像, 但细节和纹理有待改进。
2. 条件生成通过类别嵌入实现了精确的类别控制。
3. VAE+DDPM在潜空间进行扩散, 训练效率更高, 生成质量更好。
4. Flow Matching通过连续时间建模, 实现了更快的采样速度和更稳定的训练过程。
5. RePaint图像补全能够有效补全mask区域, 同时保持非mask区域不变。

通过合理的参数优化和架构改进, 我们解决了训练过程中的loss发散、数值不稳定等问题, 最终实现了高质量的图像生成和补全。

参考文献

References

- [1] Ho, J., Jain, A., Abbeel, P. (2020). Denoising diffusion probabilistic models. *Advances in Neural Information Processing Systems*, 33, 6840-6851.
- [2] Lipman, Y., et al. (2022). Flow matching for generative modeling. *International Conference on Machine Learning*, 171, 17176-17210.
- [3] Kingma, D. P., Welling, M. (2013). Auto-encoding variational bayes. *International Conference on Learning Representations*.
- [4] Lugmayr, M., et al. (2022). RePaint: Inpainting using denoising diffusion probabilistic models. *IEEE/CVF Conference on Computer Vision and Pattern Recognition*.
- [5] Animal Faces Dataset. Kaggle. <https://www.kaggle.com/datasets/andrewmvd/animal-faces>
- [6] VAE实现框架. 知乎. <https://zhuanlan.zhihu.com/p/682709613>